



DERİN ÖĞRENME İLE NÖRAL AĞLARDA DİRENÇ VERİ SETİ OLUŞTURULMASI ve SINIFLANDIRILMASI

İlker ÖNALAN¹, Eralp ÖZCAN², Raif BAYIR³

^{1,2}Karabük Üniversitesi, Yapay Zeka ve Derin Öğrenme Laboratuvarı, Karabük, Türkiye
ilkeronalan@gmail.com, eralpozccans@gmail.com

³Karabük Üniversitesi, Robot Teknolojileri Uygulama ve Araştırma Merkezi, Karabük, Türkiye
rbayir@karabuk.edu.tr



ÖZET

Günümüzde Yapay Zeka, Endüstri 4.0, Makina-İnsan Etkileşimi ve Makine-Makina etkileşimi gibi terimler ve bu terimlere bağlı yeni bilimsel yöntemler ortaya konulmaktadır. Gelişen yapay zeka ekosisteminde elektronik komponentlerden olan direnç odaklı sınıflandırılmış yapılan araştırmalar sonucunda veri setinin olduğu ancak yeterli olmadığı görülmüştür. Bir veri setinin oluşturulması, genişletilmesi ve CNN ağında eğitilmesi ile edinilen deneyimi ve kazanımları içermektedir.

Çalışmada ResNet Inception-V4 algoritması ve veri artırımı (data augmentation) yöntemi kullanılarak %82'lik bir başarıya ulaşılmıştır. DirençNet (DirençNet) içerisinde 37 sınıf 3025 görsel bulunmaktadır.

Anahtar Kelimeler: Derin Öğrenme, Nöral Ağlar, Direnç Dataset, ResNet, Veri Artırımı

ABSTRACT

Today, terms such as Artificial Intelligence, Industry 4.0, Machine-Human Interaction and Machine-Machine interaction, and new scientific methods related to these terms are presented.

In the developing artificial intelligence ecosystem, it has been seen that the data set is the result of the resistance-focused classified studies from the electronic components. In addition, it was not found to be sufficient.

It includes the experience and achievements gained through the creation, extension and training of a data set on the CNN network. In the study, ResNet Inception-V4 algorithm and data augmentation method were used to achieve 82% success. There are 37 class 3025 images in DirençNet.

Keywords: Deep Learning, Neural Networks, DirençNet, Resistor Dataset, ResNet, Data Augmentation

GİRİŞ

Yapay Zeka'nın Sinir Ağları alt dalına bağlı olan derin öğrenme yöntemleri ile elektronik devre elemanlarının sınıflandırılması üretimden, kalite kontrol sistemlerine ve geri dönüşüme kadar birçok alanda denetleme ve sınıflandırma süreçlerinden geçmektedir[8].

Günümüzde bu denetimleri yapabilen sistemler görüntü işleme vb. yöntemler kullanılmaktadır. Görüntü işleme sistemleri haricinde günümüzde başarısı kanıtlanmış yapay sinir ağı yöntemlerinden olan derin öğrenme mimarisi kullanılarak sınıflandırma yapmak donanım, maliyet ve hız gibi birçok avantaja sahiptirler.

Fakat, derin öğrenme yöntemleri için çeşitli kalite ve çeşitliliğe sahip birçok veri seti varken, elektronik elemanlar için bulunmamakta olduğu görülmüştür. Bu açığın kapatılarak bilimsel çalışmalara katkı oranının yükseltilmesi motivasyonu ile elektronik elemanlardan aynı kılıfa sahip olmasına rağmen üstündeki renk çizgilerinden dolayı ayrımı en belirgin olan dirençler için yüksek doğruluk içeren veri seti oluşturulması hedeflenmiştir.

Bu çalışmanın temel amacı, seçilmiş direnç sınıflarını sınıflandırmak için verimli bir akıllı sistem ortaya koymaktır.

MATERYAL ve METOD

Direnç, elektronik devrede akıma karşı bir zorluk göstererek akım sınırlaması yapan üzerindeki renk bantlarına göre çeşitli değerlerde olan pasif elektronik elemanıdır. Direncin birimi "Ohm" 'dur. Ohm bir iletkenden geçen elektrik akımına karşı iletkenin gösterdiği direncin birimidir.

Elektronik Elemanlar ile ilgili ImageNet gibi birçok database ortamında sınıflandırılmış görsel bulunsa da dirençlerin spesifik özelliklerinin ve direnç değerlerinin sınıflandırıldığı bir veri seti bulunmaması motivasyonumuz olmuş ve veri setine dair oluşturulan içerikler açık kaynaklı olarak paylaşılacaktır.

Veri setimizin oluşturulması için NICON D7000 Fotoğraf Makinesi ve Samsung Note 5 cep telefonu kamerası kullanılarak 37 sınıf direnç içeriği oluşturulmuştur. Verinin kalitesinin artması maksatlı yapılan testler ve deneysel çalışmalar sonucunda sınıflardaki 3932 adet görsel, çalışma için gerekli kalite şartlarını sağlayan 3025 görsele indirgenmiştir.

¼W, ½W, 1W, 2W dirençlerden oluşan veri seti için farklı ışık yoğunluğu, zemin gibi parametreler değiştirilerek görüntülenmiştir. Farklı görüntüleme cihazlarından elde edilen, görüntülerin 72DPI 700x700 pixel olacak şekilde görüntü işleme programı Adobe Photoshop CC'de işlendi. Böylece, verinin boyutu 13,6 Gb'dan 950 Mb'a düşürülerek verinin daha hızlı işenmesi ve doğruluk oranlarının artması hedeflendi.

Verisetinin içerisinden, sınıflandırılan görsellerin %70'i ağın eğitimi, %20'si test ve %10'u doğruluk için birbirlerinden farklı olacak şekilde kategorilendirildi. Daha önce yapılmış olan çalışma dahil edilmemiştir[1].

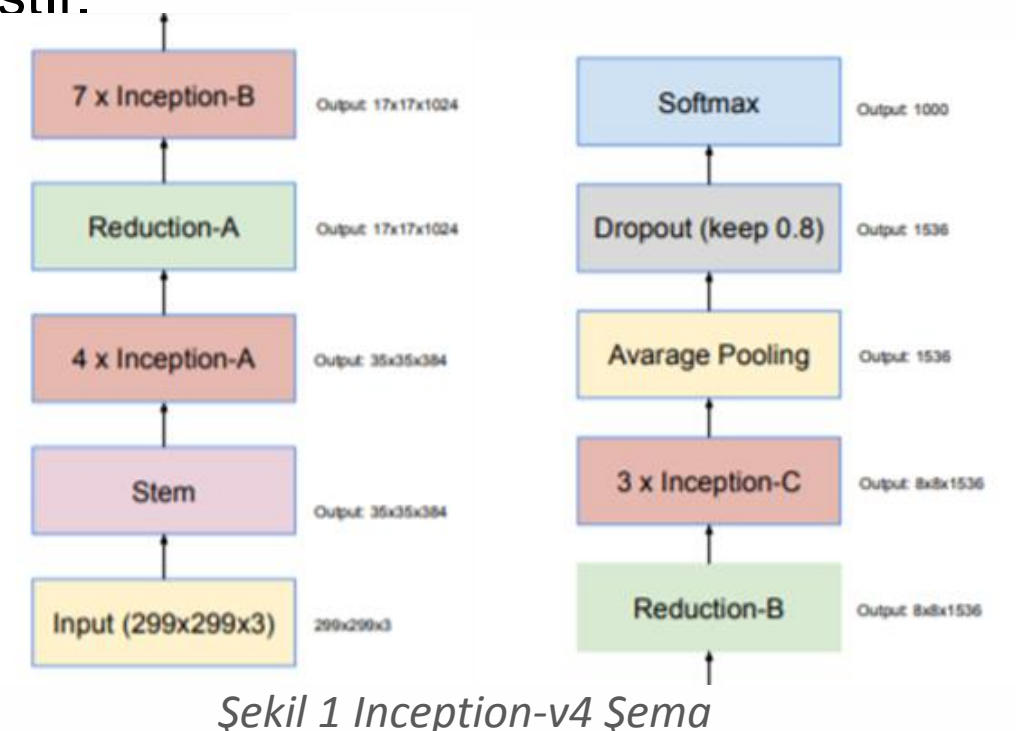
Google Drive'a yüklediğimiz data setimizi Google Bulut Sunucularında çalışan NVidia Tesla K80 GPU destekli Google Collaboratory Research Lab üzerinden Phyton 3 ile Keras kütüphanesi kodlanarak Inception ResNet V2 Algoritması kullanılmıştır[6][7]. Ağıımızın optimizasyonu için Adams Optimizasyon yöntemi seçilmiş ve 15 derecelik data zenginleştirme kullanılarak, görselin 15 derece çevrilmesiyle yeni bir veri olacak şekilde ağa tekrar veri beslemesi yapılarak, ağın veri artırımı amaçlanarak kullanılmıştır.

Adam Optimizasyon Yöntemini ağıımızda eğitim verilerine dayanan ağ ağırlıklarının yenilenmesi için kullanılan klasik stokastik derecelendirme yerine kullandığımız bir optimizasyon yöntemidir. Yöntemi, 2015 yılında ICELAR'da poster yayımında Toronto Üniversitesinden J. BA ve Open AI'den D.P. KNIGMA sunmuştur[2].

Deep Residual Networks (ResNet):

Deep residual networks (ResNet) 2015 ILSRVC (ImageNet Büyük Ölçekli Görsel Tanıma Yarışması) veri kümesinde kazanan ResNet50, Deep Residual Network mimarilerinin en yaygınlarındandır.

ResNet çok derin konvolüsyonel nöral ağların oluşmasına izin vermektedir. Konvolüsyonel katmanların yanı sıra , ResNet toplu normalleştirme ve ReLu aktivasyon fonksiyonu ile birlikte üç adet konvolüsyon katmanı olan blokları kullanmaktadır. Bu blokların kullanılması, derin ağ içerisinde ve seri normalizasyonu nedeniyle, daha az sayıda hipermetre ile ResNet'i mümkün olan en yüksek seviyede derinleştirir. Bloklar arasında ResNet önceki sürümlerde olan ağlara kıyasla daha iyi ayıklama yapabililmektedir[3]. Bu çalışmada Inception-ResNet (Inception-v4) kullanılmıştır.





Inception-V4 modeli ResNet içerisinde daha az hipermetre ile daha derin ve geniş başlangıçlı ağları çok daha verimli hale getirir. Daha önceki derin ağ modellerinde çok daha fazla eğitim kaynağı ve zaman gerekli olurken, Inception-V4 ile bağlantı iyileştirme gereksinimlerinin azalmasıyla modelin eğitilmesi daha verimli olduğu ortaya çıkmıştır[4]. Inception-V4 giriş boyutu 299x299'dur.

SONUÇ

DirençNet'i Inception-ResNet algoritması ile çalıştırdığımızda %82 doğruluk oranına ulaşılmıştır. Veriseti oluşturulmasında ışık, çekim kalitesi, görüntü benzersizliği gibi parametrelerin önemli olduğu ve başarı oranının ciddi derece etkilediği görülmüştür.

Verisetindeki örnek sayısının düşük sayıda olması derin öğrenme modellerinde ezberleme (overfitting) sürecine girdiği literatürde ve yaptığımız testlerde görülmüştür. DirençNet'de 3025 görsel 37 sınıf olması sebebi ve çalışmada kullanılan dirençlerin fiziksel özellikleri nedeniyle olası ezberlemeyi önlemek için data artırımı yöntemi ile 15 derecelik açılarda görsellerle oynayarak görsel örneklem sayısı ciddi oranda artırılmıştır.

Gelecekteki bir çalışma olarak, CNN araştırmalarındaki en son gelişmeleri kullanarak DirençNet adlı yeni data setimizi ve mimarimizi iyileştirmeyi planlıyoruz. Yeni bağlantı modelleri ve farklı optimizasyon algoritmaları ile deneyerek ve çalışmalarımızı yayınlayarak akademik katkıda bulunmak istiyoruz.



DirençNet, küçük elektronik malzemelerin boyut, renk ve elektronik kılıf gibi, makinelerin çoklu parametrelerin ve seçimlerinin zorlaştığı noktalarda yardımcı olabilecek bir altyapı oluşturmaktadır.

Endüstri 4.0 ile birlikte gelen karanlık fabrikalarda, küçük ürün seçiminde kullanılan lojistik ve paketleme sistemlerinde görüntü işleme tekniklerinin derin sinir ağı yapıları ile çalışmasına yardımcı olacağı öngörülmektedir.

ResNet mimarisinin veri çoğaltma yöntemleriyle küçük detaylara sahip ürünlerin, az örneklem ile sağlıklı değerlendirilmesi istenilen alanlarda kullanılabileceği ortaya konulmuştur.

TEŞEKKÜR

Projemizin planlanmasında, araştırılmasında, yürütülmesinde ve oluşumunda engin bilgi ve insani değerlerinden faydalandığımız, ilgi ve desteğini esirgemeyen, yönlendirme ve bilgilendirmeleri ile çalışmamızı bilimsel temeller içinde şekillendiren Karabük Üniversitesi Robot Teknolojileri Araştırma Merkezi Müdürlüğü'ne, araştırmamızın ilk safhalarında kullanılan GPU'nun bağışlanmasıyla NVIDIA Corporation'a, çalışmamızın veri seti oluşumundaki katkılarından dolayı Karabük Üniversitesi Yapay Zeka ve Derin Öğrenme Laboratuvarı Üyelerine, projemizin geliştirilmesindeki desteklerinden dolayı Deep Learning Türkiye Topluluğuna ve eğitimimizde bu noktaya gelmemizde maddi, manevi desteklerini esirgemeyen ailelerimize teşekkürlerimizi sunarız.

KAYNAKLAR

1. I. D. Perez, "Figure out the value of a resistor from an image," 2017. [Online]. Available: <http://community.wolfram.com/groups/-/m/t/1136102>. [Accessed: 17-Feb-2018].
2. D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," arXiv preprint arXiv:1412.6980, 2014.
3. K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," Dec. 2015.
4. C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, "Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning," Feb. 2016.
5. F. Chollet, "Xception: Deep learning with depthwise separable convolutions," arXiv preprint, 2016.
6. A. Google. (2017) Google colaboratory. [Online]. Available: <https://colab.research.google.com/>
7. F. Chollet et al., "Keras," 2015.
8. A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in Advances in neural information processing systems, 2012, pp. 1097–1105.

Tablo1 DirençNet Dataset İçerik Tablosu

DirençNet Dataset İçerikleri (%70 Eğitim, Yaklaşık %20Test ve %10 Val)											
	Eğitim	Test	Val		Eğitim	Test	Val		Eğitim	Test	Val
10 R 1/4W	49	14	7	20 K 1/4W	40	11	6	470 R 1/4W	121	35	17
100 R 1/4W	81	23	12	220 K 1/4W	33	10	5	470 R 1W	46	13	7
10 R 1W	43	12	7	220 R 2W	63	18	9	5.1 K 1/4W	30	7	3
10 R 2W	69	19	10	22 R 1/4W	25	8	4	5.6 K/4W	61	17	9
11 M 1/2W	51	14	7	24 K 1/2W	63	18	9	56 K 1W	34	10	5
150 R 1/4W	52	14	7	270 K 1/4W	52	15	8	5.1 K 1/4W	54	15	8
150 R 1/8W	50	14	7	27 R 1W	38	11	5	6.8 K 1/4W	52	14	7
15 R 1/4W	81	22	12	2 R 1W	56	15	5	620 R 1/4W	57	16	8
180 K 1/2W	69	19	10	3.9 K 1/4W	56	16	8	68 K 1W	66	19	10
1 K 1/4W	57	16	8	330 R 1/4W	36	10	5	7.5 K 1/4W	56	16	8
1 K 2W	44	12	6	33 K 2W	87	24	12	8.2 K 1/4W	53	14	7
1 M 1/4W	56	16	8	4.7 K 1/4W	63	18	9	820 R 1/4W	68	19	10
2.2 K 1/4W	44	12	6	4700 Moh	72	20	10				